

Project_1: Implementation and Experimental Evaluation of Basic DHTs

Ιωάννης Καλδίρης

Τεχνολογίες Αποκεντρωμένων Δεδομένων

Σκοπός εργασίας

Οι Κατανεμημένοι Πίνακες Κατακερματισμού (Distributed Hash Tables - DHTs) αποτελούν ένα θεμελιώδες στοιχείο στις κατανεμημένες υποδομές Peer-to-Peer (P2P), επιτρέποντας την αποθήκευση και ανάκτηση δεδομένων με αποδοτικό και αποκεντρωμένο τρόπο. Σκοπός αυτής της εργασίας είναι η υλοποίηση και πειραματική αξιολόγηση βασικών DHTs, με έμφαση στα πρωτόκολλα Chord και Pastry. Μέσω της ανάπτυξης αυτών των πρωτοκόλλων, θα διερευνηθεί η αποδοτικότητα των βασικών λειτουργιών, όπως η εισαγωγή και η διαγραφή κλειδιών, η αναζήτηση δεδομένων και η διαχείριση δυναμικών μεταβολών, όπως η προσθήκη ή η αποχώρηση κόμβων.

Η πειραματική αξιολόγηση θα πραγματοποιηθεί χρησιμοποιώντας πραγματικά ή συνθετικά δεδομένα, με ιδιαίτερη έμφαση στη χρήση του Coffee Reviews Dataset από το Kaggle. Το εν λόγω dataset περιλαμβάνει κριτικές καφέ μεταξύ 2017-2022 και παρέχει τη δυνατότητα επεξεργασίας δεδομένων βάσει χαρακτηριστικών, όπως το όνομα του χαρμανιού, ο τύπος του καβουρδίσματος, η τιμή και η γεωγραφική προέλευση των κόκκων καφέ. Στο πλαίσιο της εργασίας, θα αναζητηθούν οι N κορυφαίες παρόμοιες κριτικές για την περίοδο 2019-2021 με βαθμολογία άνω του 94 και τιμή ανά 100g μεταξύ 4\$ και 10\$, όπου N είναι μια μεταβλητή καθοριζόμενη από τον χρήστη.

Η κατανεμημένη δομή των DHTs θα αξιολογηθεί σε πραγματικό ή εικονικό περιβάλλον, χρησιμοποιώντας νήματα και sockets ή σύγχρονες τεχνολογίες όπως Docker και Kubernetes, για την εξασφάλιση ευέλικτης και κλιμακούμενης υλοποίησης. Επιπλέον, κάθε peer θα εξοπλιστεί με τοπικούς μηχανισμούς πολυδιάστατης ευρετηρίασης και Locality-Sensitive Hashing (LSH) για την επιτάχυνση των αναζητήσεων βάσει δευτερευόντων χαρακτηριστικών. Τέλος, θα πραγματοποιηθεί σύγκριση των πρωτοκόλλων Chord και Pastry, με ανάλυση της απόδοσής τους ως προς τον αριθμό των hops που απαιτούνται για κάθε λειτουργία.

Το πρωτόκολλο CHORD και PASTRY

Τα πρωτόκολλα Chord και Pastry είναι δύο από τις πιο διαδεδομένες μεθόδους κατανεμημένης δρομολόγησης και αποθήκευσης δεδομένων σε συστήματα Peer-to-Peer. Και τα δύο χρησιμοποιούν τεχνικές Κατανεμημένου Κατακερματισμού (DHT) για την αντιστοίχιση κλειδιών σε κόμβους του δικτύου, επιτρέποντας την αποκεντρωμένη διαχείριση δεδομένων χωρίς την ανάγκη για κεντρικό έλεγχο.

Το Chord βασίζεται σε έναν μονοδιάστατο κυκλικό χώρο τιμών (ring topology), όπου κάθε κόμβος έχει ένα μοναδικό αναγνωριστικό (ID) που προκύπτει από την εφαρμογή μίας συνάρτησης κατακερματισμού (συνήθως SHA-1). Κάθε κλειδί δεδομένων (key) χαρτογραφείται σε έναν κόμβο βάσει της ίδιας συνάρτησης, και η δρομολόγηση γίνεται με τη βοήθεια ένα σύνολο από pointers (finger table), που επιτρέπει γρήγορη αναζήτηση σε $O(\log N)$ hops.

Αντίθετα, το Pastry είναι ένα πρωτόκολλο δρομολόγησης βασισμένο σε πρόθεμα (prefix-based routing), που οργανώνει τους κόμβους σε μια δέντρομορφη ιεραρχία. Ο κάθε κόμβος διατηρεί μια δομή δρομολόγησης που περιλαμβάνει τρεις πίνακες:

- Routing Table - Επιταχύνει την αναζήτηση με βάση το πρόθεμα.
- Leaf Set - Διατηρεί γειτονικούς κόμβους για την αποθήκευση δεδομένων.
- Neighborhood Set - Περιέχει κόμβους κοντά στον συγκεκριμένο peer.
- Η αναζήτηση ενός δεδομένου σε Pastry απαιτεί περίπου $O(\log N)$ hops, όπως και στο Chord, αλλά εκμεταλλεύεται την τοπολογία του δικτύου για βελτιστοποίηση των καθυστερήσεων.

Σύγκριση μεταξύ πρωτοκόλλων

Η επιλογή μεταξύ Chord και Pastry εξαρτάται από τις απαιτήσεις του συστήματος, καθώς κάθε πρωτόκολλο έχει πλεονεκτήματα και μειονεκτήματα.

Αρχιτεκτονική και Δομή Δρομολόγησης

Το Chord χρησιμοποιεί έναν μονοδιάστατο κυκλικό χώρο, γεγονός που το καθιστά απλούστερο στην κατανόηση και υλοποίηση.

Το Pastry χρησιμοποιεί μια δένδροειδή δομή βασισμένη σε πρόθεμα, η οποία επιτρέπει αποδοτικότερη αναζήτηση με βάση την τοπολογία του δικτύου.

Αποδοτικότητα Αναζήτησης

Και τα δύο πρωτόκολλα επιτυγχάνουν δρομολόγηση σε $O(\log N)$ hops.

Το Pastry προσφέρει μικρότερη latency σε δίκτυα με φυσική τοπολογική εγγύτητα, ενώ το Chord απαιτεί επιπλέον hops αν η κατανομή των κόμβων δεν είναι ισορροπημένη.

Διαχείριση Δυναμικών Αλλαγών

Στο Chord, η ένταξη ή αποχώρηση κόμβων μπορεί να επηρεάσει σημαντικά το finger table, οδηγώντας σε αυξημένη καθυστέρηση προσαρμογής.

Το Pastry χρησιμοποιεί μια πιο προσαρμόσιμη στρατηγική ενημέρωσης, καθώς η δρομολόγηση με βάση πρόθεμα μειώνει τις ανάγκες ενημέρωσης πινάκων δρομολόγησης.

Υλοποίηση

Το Chord είναι απλούστερο στην υλοποίηση και λειτουργεί αποδοτικά σε μικρότερα δίκτυα.

Το Pastry είναι προτιμότερο για ευρείας κλίμακας κατανεμημένες εφαρμογές, καθώς προσαρμόζεται καλύτερα σε ετερογενή περιβάλλοντα.

Αποτελέσματα

Εκτελέσαμε διάφορες λειτουργίες όπως την εισαγωγή του συνόλου , διαγραφές και ανανεώσεις .

Πήραμε τα παρακάτω αποτελέσματα από 100 ερωτήματα αναζήτησης

Χρόνος Chord : 3.43s

Χρονος Pastry: 3.54s

Σε 100 διαγραφές πήραμε τα παρακάτω:

Χρόνος Chord : 2.34s

Χρονος Pastry: 2.43s

Επίσης ο χρόνος για τα joins ήταν 3.12 και 3.43 s

Χρόνος Chord : 3.14s

Χρονος Pastry: 3.32s

Όπως διαπιστώνουμε δεν έχουμε πολύ μεγάλες διαφορές παρόλα αυτά φαίνεται ο Chord να έχει καλύτερη συμπεριφορά στο σύνολο που εξετάζουμε.